

MÓDULOS 7 – 14

Análise de Dados com Python

**Bibliotecas ■ NumPy ■ Pandas ■ Limpeza de Dados
Estatística ■ Visualização ■ EDA ■ Projeto Final**

Célula de estudos em de estatística e análise de dados - Pacce-UFCA

Geraldo Luiz Carvalho 2026

SUMÁRIO

07

Bibliotecas

Ferramentas prontas para análise

08

NumPy

Arrays e operações matemáticas

09

Pandas

DataFrames e manipulação

10

Limpeza de Dados

Tratamento de problemas reais

11

Estatística Descritiva

Média, mediana e desvio padrão

12

Visualização

Gráficos de barras e linhas

13

Análise

Exploratória
Data storytelling de insights

14

Projeto Final

Fluxo completo de análise

► O que são Bibliotecas?

Bibliotecas são **ferramentas prontas** que outros desenvolvedores criaram para facilitar seu trabalho. Em vez de escrever tudo do zero, você importa funções já testadas e otimizadas.

→ Analogia: Como usar uma calculadora científica ao invés de fazer contas na mão

Fluxo de um Projeto de Dados



Principais Bibliotecas

N NumPy

Computação numérica e arrays

P Pandas

Manipulação de dados

M Matplotlib

Visualização e gráficos

Essas 3 bibliotecas formam a base da análise de dados em Python

► Introdução ao NumPy

NumPy (Numerical Python) é a biblioteca fundamental para computação científica. Seu elemento central é o **array** — uma estrutura de dados que armazena valores numéricos de forma eficiente.

- Arrays são como listas, mas muito mais rápidos para cálculos matemáticos

Operações Matemáticas

 μ

Média
`np.mean()`

 Σ

Soma
`np.sum()`

 $\uparrow$

Máximo
`np.max()`

★ Aplicação Real

Análise de Notas — 10.000 Alunos

Média Geral

7.4

Nota Máxima

10.0

Nota Mínima

3.2

Desvio Padrão

1.8

Código:

```
notas = np.array([8.5, 7.2, 9.1, ...])  
media = np.mean(notas)  
maxima = np.max(notas)
```

■ Exercício Prático

Analise um conjunto de 1.000 notas. Calcule: média, mediana, desvio padrão, nota máxima e mínima. Identifique quantos alunos ficaram acima da média.

► O que é um DataFrame?

Um DataFrame é uma **tabela inteligente** — como uma planilha Excel, mas com superpoderes. Você pode filtrar, ordenar, agrupar e analisar dados de forma programática.

- Pandas transforma dados brutos em informação estruturada e analisável

Lendo Arquivos CSV

```
import pandas as pd
df = pd.read_csv('dados.csv')
```

→ Uma linha de código carrega milhares de registros

Métodos de Exploração

df.head()

Primeiras 5 linhas

df.info()

Estrutura e tipos

df.describe()

Estatísticas

★ Aplicação Real — Base de Clientes

ID	Nome	Idade	Cidade	Compras
001	Ana Silva	28	São Paulo	R\$ 1.250
002	Bruno Costa	35	Rio de Janeiro	R\$ 3.400
003	Carla Dias	22	Belo Horizonte	R\$ 890
004	Daniel Lima	41	São Paulo	R\$ 5.600
005	Elisa Martins	29	Curitiba	R\$ 2.100

5

Registros

31

Média Idade

R\$ 2.6k

Média Compras

Insights: Clientes de São Paulo têm maior ticket médio. Faixa etária 25-40 anos é a mais ativa.

Limpeza de Dados

► Problemas Reais

Dados do mundo real são **sempre sujos**. Antes de analisar, você precisa identificar e tratar problemas comuns:

✗ **Dados Faltantes**
Campos vazios, NaN,
null

✗ **Registros Duplicados**
Mesma informação repetida

✗ **Erros e Inconsistências**
Idades negativas, textos em
números

★ Caso Real

Pesquisa com Respostas Incompletas

Em uma pesquisa de 5.000 respondentes, 23% deixaram campos em branco. Como lidar?

- Analisar padrão de missing values
- Decidir: preencher ou remover?
- Documentar decisões tomadas

Técnicas de Tratamento

df.fillna()

Preencher valores ausentes

```
# Preencher com média  
df['idade'].fillna(df['idade'].mean())  
# Preencher com valor fixo  
df['cidade'].fillna('Não informado')
```

df.dropna()

Remover linhas com dados faltantes

```
# Remover todas as linhas com NaN  
df.dropna()  
# Remover apenas coluna específica  
df.dropna(subset=['salario'])
```

⚠ Regra de Ouro

Nunca elimine mais de 30% dos dados sem justificativa técnica. Sempre documente o que foi alterado e por quê.

► Média

 μ

Valor Central

A média é a soma de todos os valores dividida pelo número de observações. Representa o "centro de massa" dos dados.

Exemplo: Notas [8, 7, 9, 6, 10]
Média = $(8+7+9+6+10) / 5 = 8.0$

- Sensível a outliers

► Mediana

M

Valor do Meio

A mediana é o valor central quando os dados estão ordenados. Divide o conjunto em duas partes iguais.

Exemplo: Notas [6, 7, 8, 9, 10]
Mediana = 8 (valor central)

- Robusta a outliers

► Desvio Padrão

 σ

Variabilidade

Mede o quanto os dados se dispersam em torno da média. Quanto maior, mais espalhados estão os valores.

Exemplo: $\sigma = 1.5$
Significa que a maioria dos valores está entre 6.5 e 9.5

- Mede dispersão

★ Aplicação Real — Análise de Notas

Média

7.4

Mediana

7.6

Desvio Padrão

1.8

Alunos

10k

Interpretação: A média (7.4) próxima da mediana (7.6) indica distribuição simétrica. O desvio padrão de 1.8 mostra variabilidade moderada — a maioria dos alunos está entre 5.6 e 9.2.

Visualização de Dados

► Por que usar Gráficos?

O cérebro humano processa imagens **60 mil vezes mais rápido** que texto. Gráficos transformam números em histórias visuais compreensíveis.



Identificar padrões



Comparar dados



Comunicar insights

Gráfico de Barras

Quando Utilizar:

- Comparar categorias distintas
- Mostrar ranking ou ordenação
- Visualizar frequências
- Destacar diferenças entre grupos

```
plt.bar(categorias, valores)
```


Gráfico de Linhas

Quando Utilizar:

- Mostrar tendências temporais

★ Aplicação Real — Vendas por Mês

Vendas (R\$ mil)



Total Anual

R\$ 4.2M

Média Mensal

R\$ 350k

Melhor Mês

Dezembro

Insights: Pico em dezembro (Natal) e queda em fevereiro. Sazonalidade clara permite planejamento de estoque e marketing.

Análise Exploratória (EDA)

► O que é EDA?

EDA (Exploratory Data Analysis) é o processo de **explorar dados antes de modelar**. É como investigar uma cena de crime — você precisa entender o que aconteceu antes de tirar conclusões.

→ Objetivo: Descobrir padrões, detectar anomalias, testar hipóteses e verificar suposições

Perguntas Importantes

?

Quem compra mais?

Segmentação de clientes

?

Quando compra?

Padrões temporais

?

Por quê compra?

Motivações e drivers

?

Como se comporta?

Hábitos e recorrência

★ Caso Prático — Base de Vendas

Dataset: 50.000 transações

Total de Clientes

12.450

Ticket Médio

R\$ 187

Taxa de Conversão

3.2%

Tempo Médio

5.4 dias

Descobertas da EDA

- 20% dos clientes geram 60% da receita (Princípio de Pareto)
- Compras aumentam 40% nos finais de semana
- Clientes entre 25-35 anos têm maior valor de vida (LTV)
- Produtos eletrônicos têm maior margem, mas menor frequência

Ação: Focar marketing no segmento 25-35 anos, criar promoções de fim de semana, desenvolver programa de fidelidade para top 20%.

Projeto Final

★ Fluxo Completo de Análise

1

Importar Dados

Carregar CSV, conectar API ou consultar banco de dados. Validar formato e estrutura.

```
pd.read_csv() | pd.read_sql() | requests.get()
```



2

Limpar Dados

Tratar missing values, remover duplicados, corrigir erros e padronizar formatos.

```
df.dropna() | df.fillna() | df.drop_duplicates()
```



3

Analisar

Calcular estatísticas descritivas, identificar correlações e segmentar dados.

```
df.describe() | df.corr() | df.groupby()
```



4

► Checklist do Projeto

☐ Definir pergunta de negócio☐ Coletar e importar dados☐ Limpar e preparar dataset☐ Realizar análise exploratória☐ Criar visualizações☐ Tirar conclusões☐ Documentar metodologia

★ Dica Final

Um bom projeto de dados não é sobre código perfeito — é sobre responder perguntas de negócio com clareza e evidências.

Próximos Passos

► Consolidar o Aprendizado

1. Refaça os exercícios dos módulos 7-14 sem olhar as respostas

2. Crie seu próprio dataset e aplique todo o pipeline de análise

3. Documente cada etapa em um notebook Jupyter organizado

Prática Contínua

A maestria vem da repetição. Pratique diariamente com **datasets reais** disponíveis em plataformas como Kaggle, UCI Machine Learning Repository e IBGE.

→ Desafio: Analise 1 dataset por semana durante 3 meses

Caminhos de Especialização

ML Machine Learning

scikit-learn, TensorFlow, modelos preditivos

BD Big Data

Spark, Hadoop, processamento distribuído

BI Business Intelligence


Power BI, Tableau, dashboards executivos

DE Data Engineering

ETL, pipelines, data warehouses, cloud

★ Construa seu Portfólio

Documente todos os projetos no GitHub. Um portfólio sólido vale mais que certificados — é sua prova prática de competência.



Continue Programando!

**A melhor forma de aprender é
praticando.
Mãos na massa!**

- **CURSO DE ANÁLISE DE DADOS COM PYTHON**